

Optimal lagerbeholdning for BiteBurst: En SARIMA-basert tilnærming til prognose og sikkerhetslager

Forfatter: Kjetil Tronstad Lund

Totalt antall sider inkludert forsiden:

Molde, 31. mai 2026

Obligatorisk egenerklæring

Den enkelte student er selv ansvarlig for å sette seg inn i hva som er lovlige hjelpemidler, retningslinjer for bruk av disse og regler om kildebruk. Erklæringen skal bevisstgjøre studentene på deres ansvar og hvilke konsekvenser fusk kan medføre. Manglende erklæring fritar ikke studentene fra sitt ansvar.

Personvern

Personopplysningsloven

Har oppgaven vært vurdert av NSD? nei

- Jeg erklærer at oppgaven ikke omfattes av Personopplysningsloven. Datagrunnlaget består utelukkende av simulerte salgsdata fra dataspillet Big Ambitions og inneholder ingen personopplysninger.

Helseforskningsloven

Har oppgaven vært til behandling hos REK? nei

Publiseringsavtale

Studiepoeng:

Veileder:

Jeg/vi gir herved Høgskolen i Molde en vederlagsfri rett til å gjøre oppgaven tilgjengelig for elektronisk publisering: ja

Er oppgaven båndlagt (konfidensiell)? nei

Dato:

Sammendrag

Denne rapporten undersøker hvordan historiske salgsdata kan benyttes til å fastsette optimalt lagernivå for hvert av fire hurtigmatutsalgssteder i den fiktive bedriften BiteBurst. Datagrunnlaget er hentet fra dataspillet Big Ambitions og består av 101 observasjoner av rullerende 7-dagerssummer for åtte produktkategorier per utsalgssted.

Analysen avdekket statistisk signifikante ukentlige salgsmønstre, noe som motiverte valget av sesong-ARIMA (SARIMA) som prognosemodell med en ukesperiode på syv dager. Modellparametere ble valgt automatisk via `auto_arima` basert på AIC-kriteriet, og det ble tilpasset 32 individuelle modeller – én per produkt per utsalgssted.

Resultatene viser at SARIMA-modellene predikerer etterspørselen med god nøyaktighet for de fleste produkter, med gjennomsnittlig absolutt prosentfeil (MAPE) på 1–7 % for majoriteten. Høyere usikkerhet ble observert for Pommes frites og Pølse i utvalgte utsalgssteder. Basert på prognosene og et sikkerhetsslager beregnet for 95 % servicegrad presenteres konkrete lagernivåanbefalinger per produkt per utsalgssted, som gir hvert sted grunnlag for syv dagers drift uten levering fra sentrallager. Rapporten diskuterer også modellenes begrensninger og mulighetene for å overføre metodikken til reelle forretningsdata.

Abstract

This report investigates how historical sales data can be used to determine optimal inventory levels for four fast-food outlets in the fictional company BiteBurst. The data was collected from the simulation game Big Ambitions and consists of 101 observations of rolling 7-day sales sums across eight product categories per outlet.

Analysis revealed statistically significant weekly sales patterns, motivating the choice of Seasonal Autoregressive Integrated Moving Average (SARIMA) as the forecasting model with a seasonal period of seven days. Model parameters were selected automatically via `auto_arima` based on the AIC criterion, resulting in 32 individual models – one per product per outlet.

Results show that SARIMA models predict demand with high accuracy for most products, with mean absolute percentage error (MAPE) of 1–7 % for the majority. Higher uncertainty was observed for Pommes frites and Pølse at selected outlets. Based on the forecasts and a safety stock calculated for a 95 % service level, specific recommended stock levels per product per outlet are reported, enabling each outlet to operate for seven days without replenishment from the central warehouse. The report also discusses model limitations and the potential for applying the methodology to real business data.

Innhold

1. Innledning
 - 1.1 Problemstilling
 - 1.2 Avgrensninger
 - 1.3 Antagelser
2. Litteratur
3. Teori
4. Casebeskrivelse
5. Metode og data
 - 5.1 Metode
 - 5.2 Data
6. Modelling
7. Analyse
8. Resultat
9. Diskusjon
10. Konklusjon
11. Bibliografi
12. Vedlegg

Figurliste | Tabelliste

Figurliste

Figur	Beskrivelse	Kapittel
Figur 1	ACF og PACF for Pommes frites ved Hell's Kitchen – motiverer valg av sesongperiode $s = 7$	5.1
Figur 2	Pommes frites – rullerende 7-dagers salg per utsalgssted med begge valideringsvinduer	7.3
Figur 3	SARIMA-prognose for Pommes frites ved Hell's Kitchen (V2-MAPE = 1,5 %)	7.3
Figur 4	SARIMA-prognose for Pommes frites ved Murray Hill (V2-MAPE = 21,6 %)	7.4
Figur 5	Residualdiagnostikk for Brus ved Garment District – standardiserte residualer og ACF	7.5

Figur	Beskrivelse	Kapittel
Figur 6	Anbefalt ukentlig bestillingsmengde per produkt per utsalgssted ved 95 % servicegrad	8.5
Figur 7	Residualfordeling for Brus (GM) og Pommes frites (MH) med normalfordeling $N(0, 1)$ og Shapiro-Wilk-test	9.4

Tabelliste

Tabell	Beskrivelse	Kapittel
Tabell 1	Oversikt over BiteBursts utsalgssteder	4
Tabell 2	Ukentlig prognose per utsalgssted – alle produkter summert	4
Tabell 3	Identifiserte og korrigerte registreringsfeil	5.2
Tabell 4	Deskriptiv statistikk for rullerende 7-dagers salgsvolum – GM	5.2
Tabell 5	Deskriptiv statistikk for rullerende 7-dagers salgsvolum – HK	5.2
Tabell 6	Deskriptiv statistikk for rullerende 7-dagers salgsvolum – LM	5.2
Tabell 7	Deskriptiv statistikk for rullerende 7-dagers salgsvolum – MH	5.2
Tabell 8	Oversikt over tilpassede SARIMA-modeller med modellorden og AIC	6.3
Tabell 9a	SARIMA MAPE (%) – Valideringsvindu V1 (dag 88–94)	7.1
Tabell 9b	SARIMA MAPE (%) – Valideringsvindu V2 (dag 95–101)	7.1

Tabell	Beskrivelse	Kapittel
Tabell 9c	SARIMA MAPE (%) – Gjennomsnitt V1 og V2	7.1
Tabell 9d	Naiv referanseprognose MAPE (%) – V2-vinduet	7.1
Tabell 9e	Ljung-Box p-verdi (lag 7) per produkt og utsalgssted	7.5
Tabell 10	Anbefalte lagernivåer for Garment District ved 95 % servicegrad	8.1
Tabell 11	Anbefalte lagernivåer for Hell's Kitchen ved 95 % servicegrad	8.2
Tabell 12	Anbefalte lagernivåer for Lower Manhattan ved 95 % servicegrad	8.3
Tabell 13	Anbefalte lagernivåer for Murray Hill ved 95 % servicegrad	8.4

1 Innledning

Effektiv lagerstyring er en av de mest kritiske faktorene for lønnsomheten i detaljhandel og serveringsbransjen. En mangelsituasjon – ofte omtalt som stock-out – innebærer at et produkt ikke er tilgjengelig når kundene etterspør det, noe som resulterer i tapte inntekter, redusert kundetilfredshet og i verste fall varig tap av kunder. På den andre siden medfører overlagering unødvendig kapitalbinding, økte lagerkostnader og risiko for at ferskvarer ikke kan benyttes. Den grunnleggende utfordringen for enhver varehandler er å balansere disse to motsigende hensynene ved å opprettholde et lagernivå som er høyt nok til å dekke etterspørselen, men lavt nok til at kapitalen utnyttes effektivt (Silver et al., 2017).

Tradisjonelle tilnærminger til lagerstyring baserer seg på gjennomsnittlig etterspørsel og statistiske mål for variasjon for å beregne sikkerhetslager og bestillingspunkter. I takt med økt datatilgjengelighet har imidlertid kvantitative prognosemetoder blitt stadig mer utbredt. Blant disse har tidsrekkemodeller som ARIMA og dens sesongbaserte utvidelse SARIMA vist seg å være godt egnet for etterspørselsprognoser i detaljhandelen, særlig der salgsdata viser sesongmønstre eller autokorrelasjon over tid (Hyndman & Athanasopoulos, 2021). En viktig fordel med slike statistiske modeller er at de kan fange opp strukturen i historiske data og produsere prognoser med tilhørende usikkerhetsintervaller, som kan benyttes direkte til å dimensjonere sikkerhetslager.

Denne rapporten tar utgangspunkt i den fiktive hurtigmatbedriften BiteBurst, som opererer fire utsalgssteder i dataspillet Big Ambitions (Hovgaard & Hovgaard, 2022). Bruk av en forretningssimulator er et bevisst metodisk valg: spillets konsistente og transparente etterspørselslogikk gir et kontrollert testmiljø der metodikken kan isoleres og evalueres uten forstyrrende faktorer som kampanjer, sesongvariasjoner utenfor modellen eller konfidensialitetshensyn. Dette gjør det mulig å validere en generell analyserekke for SARIMA-basert lagerdimensjonering under realistiske, men reproducerbare betingelser – noe som er vanskeligere å oppnå med reelle forretningsdata i et avgrenset prosjekt. Med 101 daglige observasjoner av rullerende 7-dagerssummer per utsalgssted for åtte produktkategorier danner datagrunnlaget en solid basis for tidsrekkeanalyse.

Formålet med rapporten er todelt. Det *substansielle* målet er å fastsette det optimale lagernivået hvert BiteBurst-utsalgssted må holde for å kunne operere i syv dager uten levering fra sentrallager – et nivå som er særlig relevant ved leveringsforsinkelser eller andre driftsforstyrrelser. Det *metodiske* målet er å demonstrere og evaluere en reproducerbar analyserekke for SARIMA-basert etterspørselsprognose koblet direkte til sikkerhetslagerberegning via modellens prediksjonsintervaller, og å undersøke i hvilken grad denne tilnærmingen gir bedre prognosenøyaktighet enn en naiv referansem modell. Rapporten bidrar dermed med to typer innsikt: konkrete lagernivåanbefalinger for BiteBurst, og en overførbart metodikk for lageroptimalisering basert på historiske salgsdata der en åpen kildekode-løsning i Python automatiserer modellvalg og beregninger.

Rapporten er bygget opp med litteratur og teori først, etterfulgt av casebeskrivelse, data, metode og modellering, og avsluttes med analyse, resultater, diskusjon og konklusjon.

1.1 Problemstilling

Rapporten tar utgangspunkt i følgende problemstilling:

Hvordan kan SARIMA-basert etterspørselsprognose benyttes til å fastsette optimalt lagernivå per produkt per utsalgssted for hurtigmatbedriften BiteBurst, slik at hvert utsalgssted kan operere i syv dager uten levering fra sentrallager?

For å strukturere analysen deles problemstillingen inn i to delspørsmål:

1. Hvilken SARIMA-modell beskriver etterspørselen best for hvert produkt per utsalgssted, målt ved Akaikes informasjonskriterium (AIC) og gjennomsnittlig absolutt prosentfeil (MAPE)?
2. Hva er det anbefalte lagernivået per produkt per utsalgssted ved 95 % servicegrad, basert på SARIMA-prognosene og tilhørende prediksjonsintervaller?

1.2 Avgrensninger

Følgende avgrensninger er gjort for å holde problemstillingen håndterbar og analysene fokuserte.

Produktutvalg: Rapporten omfatter alle åtte produktkategoriene som selges i samtlige av BiteBursts utsalgssteder: Pizza, Salat, Pommes frites, Hamburger, Pølse, Brus, Iskrem og Kebab. Opprinnelig var omfanget avgrenset til 4–5 produkter, men siden alle åtte er felles for alle utsalgsstedene og datagrunnlaget er komplett, ble det besluttet å inkludere samtlige for et mer fullstendig analysegrunnlag.

Kostnadsmodell: Det inkluderes ikke eksplisitte kostnader for ansatte, lokaler eller utsalgspris i analysen. Fokus er utelukkende på etterspørselsprognose og lagernivåanbefaling, ikke på en fullstendig totaløkonomisk optimalisering.

Datagrunnlag: Analysen baserer seg utelukkende på simulerte data fra Big Ambitions. Resultatene skal ikke generaliseres direkte til reelle hurtigmatkjeder uten videre validering mot faktiske forretningsdata.

Bestillingsfrekvens: Det antas at utsalgsstedene mottar levering fra sentrallager én gang per uke, og at lagernivåene fastsettes for en planleggingshorisont på syv dager.

Sentrallager: Rapporten ser bort fra sentrallageret som en separat analyseenhet. Fokus er på lagernivåene i de fire utsalgsstedene.

1.3 Antagelser

Følgende antagelser er lagt til grunn for analysen.

Representativitet: Det antas at salgsdata fra Big Ambitions er tilstrekkelig representative til å identifisere etterspørselsmønstre. Spilleets etterspørselslogikk er konsistent og ble ikke påvirket av oppdateringer i observasjonsperioden.

Ukessyklus: Statistisk analyse avdekket signifikant autokorrelasjon ved lag 7 for flere produkter og utsalgssteder, noe som bekrefter at en ukentlig sesongperiode er til stede i dataene (jf. kapittel 5.1). Det antas at disse mønstrene er stabile og at en sesongperiode på syv dager er korrekt. Prosjektets opprinnelige planleggingsdokument antok at ingen sesongvariasjoner fantes i dataene — denne antagelsen ble avkreftet av den statistiske analysen og er justert her.

Servicegrad: En servicegrad på 95 % antas å være et hensiktsmessig mål for å balansere stockout-risiko mot lagerkostnader. Dette tilsvarer en z-verdi på 1,645 under normalfordelingsantagelsen.

Etterspørselsfordeling: Det antas at prognosefeil er tilnærmet normalfordelte, slik at normalfordelingens z-verdier kan benyttes til å beregne sikkerhetslager fra modellenes prediksjonsintervaller.

2 Litteratur

Forskning på etterspørselsprognoser og lagerstyring spenner over et bredt felt av metoder og anvendelsesområder. Dette kapittelet gir en oversikt over sentrale bidrag som er relevante for problemstillingen i denne rapporten: bruken av SARIMA-modeller til etterspørselsprognoser og den direkte koblingen til sikkerhetslagerberegning.

2.1 ARIMA og SARIMA i etterspørselsprognoser

Det metodologiske fundamentet for ARIMA-modellering ble lagt av Box, Jenkins, Reinsel og Ljung (2015) i standardverket *Time Series Analysis: Forecasting and Control*, som gjennom flere tiår har vært referansepunktet for praktisk tidsrekkemodellering. Box og Jenkins introduserte syklusen for identifisering, estimering og diagnostikk som ligger til grunn for manuelt modellvalg, og som er automatisert i moderne verktøy som `auto_arima`. Sesongkomponenten i SARIMA-modellen adresserer et grunnleggende fenomen i handelssektoren: at etterspørselen varierer systematisk med ukedagen, måneden eller årstiden, og at denne variasjonen er målbar og kan utnyttes i prognosene.

Hyndman og Athanasopoulos (2021) gir i *Forecasting: Principles and Practice* en bred og tilgjengelig gjennomgang av hele spekteret fra eksponentiell utjevning til ARIMA-modeller, og er en sentral kilde for vurderingen av AIC som informasjonskriterium samt for tolkning av ACF og PACF-diagnostikk. Forfatterne understreker at automatiske modellvalgsalgoritmer – som stepwise-søket i `auto_arima` – i praksis gir resultater på linje med manuelt modellvalg for de fleste datasett, mens beregningstiden reduseres dramatisk når et stort antall modeller skal tilpasses. Dette er direkte relevant for dette prosjektet der 32 individuelle modeller ble tilpasset.

Bruken av SARIMA for daglige salgsdata i mat- og detaljhandel er dokumentert i empirisk litteratur. Arunraj og Ahrens (2015) benytter SARIMA i kombinasjon med kvantilregresjon for å prognostisere daglig salg av ferskvarer i en dagligvarebutikk, og bekrefter at SARIMA-komponenten fanger opp den ukentlige sesongstrukturen godt. Studien peker samtidig på at rene SARIMA-modeller kan komme til kort for produkter med sterk ikke-lineær variasjon – et funn som er gjenkjennbart i dette prosjektets resultater for Pommes frites og Pølse. Fattah et al. (2018) demonstrerer tilsvarende at ARIMA-basert prognose gir stabil ytelse i et matvareforetak og underbygger modellklassens praktiske anvendbarhet på daglige salgsdata. Fellesnevneren på tvers av disse studiene er at daglige salgsdata fra serveringssteder og dagligvarehandel nesten alltid viser en signifikant ukentlig sesongkomponent, siden handleplanene til forbrukerne er tett koblet til ukesrytmen med toppunkter i helgene og lavere aktivitet midt i uken (Hyndman & Athanasopoulos, 2021). SARIMA med sesongperiode $s = 7$ er dermed et naturlig valg for slike data, noe som bekreftes av at alle 32 modeller i dette prosjektet fikk valgt en sesongkomponent automatisk.

Arunraj et al. (2016) utvider rammen til SARIMAX ved å inkludere eksterne

forklaringsvariabler som kampanjer og temperatur i daglige matvaresalgsdata, og finner at dette ytterligere reduserer prognosefeil for volatile produktkategorier. Denne utvidelsen er relevant som neste metodeskritt for BiteBurst-dataene dersom kampanje- eller sesongdata blir tilgjengelige (jf. kapittel 9.6), men forutsetter at slike variabler faktisk registreres systematisk.

2.2 Lagerstyring og sikkerhetslager

Den klassiske teorien for sikkerhetslager tar utgangspunkt i at etterspørselen er stokastisk og at målet er å fastsette et lagernivå som balanserer stockout-risiko mot lagerkostnader. Silver, Pyke og Thomas (2017) gir en samlet fremstilling av metodene for bestillingspunktsmodeller, servicegradbegreper og beregning av sikkerhetslager under ulike fordelingsantagelser. Den klassiske formelen $SS = z_{\alpha} \cdot \sqrt{L}$ er en direkte implementasjon av denne teorien, der z -verdien fra normalfordelingen kobler den ønskede servicegraden til det nødvendige lagernivået. Forutsetningen om normalfordelte prognosefeil er en forenkling som fungerer godt for produkter med jevn og relativt stabil etterspørsel, men som kan undervurdere risikoen for produkter med tunge haler i fordelingen eller systematiske trender.

Chopra og Meindl (2019) setter lagerstyringen inn i et bredere forsyningskjedeperspektiv og understreker at den optimale lagerpolitikken ikke kan ses isolert fra bestillingsfrekvens, ledetid og leverandørvariabilitet. I BiteBurst-konteksten er disse parameterne relativt enkle: ukentlig bestillingssyklus og ingen eksplisitt ledetidsvariasjon. Dette forenkler sikkerhetslagerberegningen til å handle primært om etterspørselsvariasjon over en fast planleggingshorisont, noe SARIMA-prediksjonsintervallene er godt egnet til å kvantifisere.

2.3 Integrering av prognose og lagerstyring

En viktig utvikling i litteraturen er koblingen mellom statistiske prognosemodeller og sikkerhetslagerberegning. Fremfor å bruke historisk standardavvik som en separat inputparameter til sikkerhetslageret, utnytter den tilnærmingen som er benyttet i denne rapporten – direkte avlesning av prediksjonsintervaller fra SARIMA-modellen – den modellspesifikke usikkerheten slik den er estimert av modellen selv. Fordelen er at sikkerhetslageret automatisk vil være høyere for produkter og perioder der modellen er usikker, og lavere der modellen er presis, uten at dette krever separate vurderinger for hvert produkt (Silver et al., 2017). Denne tilnærmingen er i tråd med prinsippet om at prognose og lagerdimensjonering bør behandles som en integrert prosess fremfor to adskilte trinn.

Babai et al. (2013) analyserer empirisk sammenhengen mellom prognosenøyaktighet og lagerytelse i en to-trinns forsyningskjede med ARIMA(0,1,1)-etterspørsel, basert på 329 vareenheter fra en stor europeisk dagligvareaktør. Studien finner at bedre prognosenøyaktighet konsekvent gir lavere sikkerhetslagerbehov og færre stockout-hendelser, og gir dermed direkte empirisk støtte til motivasjonen for å benytte SARIMA fremfor naive prognosemetoder.

Sammenligningen mot naiv baseline i dette prosjektet (Tabell 9d) kan ses som en praktisk replikasjon av denne logikken på BiteBurst-data. Gilbert (2005) viser fra et teoretisk perspektiv at ARIMA-modellering av etterspørsel kan redusere bullwhip-effekten sammenlignet med glidende gjennomsnitt i flerleddede forsyningskjeder – relevant for BiteBurst der utsalgsstedenes etterspørsel propagerer oppstrøms til sentrallageret. Begge studier understreker at valget av prognosemodell ikke bare påvirker prognosenøyaktigheten isolert, men også de samlede lagerkostnadene og servicegradens pålitelighet i hele forsyningskjeden.

2.4 Alternative prognosemodeller

Tre klasser av modeller er særlig relevante som alternativer til SARIMA for etterspørselsprognoser med sesongkomponenter, og er inkludert her for å begrunne metodevalget i kapittel 5.1.

Eksponentiell utjevning – Holt-Winters: Holt-Winters-metoden (også kalt ETS – Error, Trend, Seasonality) modellerer trend og sesong direkte gjennom glattingsparametere og krever ingen stasjonærhetstransformasjoner (Hyndman & Athanasopoulos, 2021). En sentral fordel er at nylige observasjoner vektet høyere enn eldre, noe som gjør metoden mer responsiv overfor trendsifter – en egenskap som ville vært nyttig for Murray Hills vekstsituasjon i dette prosjektet. Svakheten er at Holt-Winters ikke produserer like statistisk velfunderte prediksjonsintervaller som SARIMA, og at den ikke fanger opp kompleks autokorrelasjonsstruktur utover trend og sesong.

SARIMAX: En direkte utvidelse av SARIMA der eksterne forklaringsvariabler inkluderes. Arunraj et al. (2016) viser empirisk at SARIMAX reduserer prognosefeil for volatile produktkategorier i matvarebransjen sammenlignet med ren SARIMA, særlig der kampanjer og sesongvariabler påvirker etterspørselen. Metoden er aktuell der slike variabler er tilgjengelige og målbare, men introduserer økt modellkompleksitet og krav til datakvalitet for de eksterne forklaringsvariablene.

Maskinlæringsmetoder: Gradient boosting og rekurrente nevralt nettverk (LSTM) har vist lovende resultater for etterspørselsprognoser på store datasett med mange produkter og komplekse ikke-lineære mønstre (Hyndman & Athanasopoulos, 2021). Disse metodene krever imidlertid typisk vesentlig større datamengder for stabil parameterestimering, er vanskeligere å tolke og validere med korte tidsrekker, og produserer ikke prediksjonsintervaller av samme statistiske kvalitet som SARIMA uten tilleggsmetodikk.

Disse alternativene drøftes videre i lys av resultatene i kapittel 9.6.

3 Teori

3.1 Tidsrekker og stasjonærhet

En tidsserie er en sekvens av observasjoner samlet over tid i jevne tidsintervaller. For at klassiske statistiske metoder skal kunne benyttes direkte på tidsrekke-data, er det en forutsetning at serien er stasjonær – det vil si at seriens statistiske egenskaper, særlig gjennomsnitt og varians, er konstante over tid (Hyndman & Athanasopoulos, 2021). Mange reelle tidsrekker er ikke-stasjonære: de kan oppvise trender, sesongsvingninger eller endringer i variansen over tid.

En vanlig teknikk for å oppnå stasjonærhet er differensiering, der man erstatter de originale verdiene med differansen mellom påfølgende observasjoner. Graden av differensiering betegnes med d , slik at $d = 1$ innebærer at man tar førsteordens differansen $\Delta y_t = y_t - y_{t-1}$, og $d = 2$ innebærer ytterligere differensiering. Augmented Dickey-Fuller-testen (ADF) er en standard statistisk test for å undersøke om en tidsserie inneholder en enhetsrot, noe som er ensbetydende med ikke-stasjonærhet. En signifikant ADF-testverdi ($p < 0,05$) indikerer at nullhypotesen om enhetsrot kan forkastes, og at serien er stasjonær (Box et al., 2015).

3.2 ARIMA-modellen

ARIMA(p, d, q) – Autoregressive Integrated Moving Average – er en familie av modeller for å beskrive og prognostisere tidsrekker (Box et al., 2015). Modellen har tre komponenter:

Autoregressive (AR) ledd av orden p betyr at den nåværende verdien modelleres som en lineær kombinasjon av de p foregående verdiene:

$$y_t = c + \varphi_1 y_{t-1} + \varphi_2 y_{t-2} + \dots + \varphi_p y_{t-p} + \varepsilon_t$$

der φ_i er autoregresjonskoeffisientene og ε_t er hvit støy.

Integrated (I) komponent av orden d angir at serien er differensiert d ganger for å oppnå stasjonærhet. For $d = 1$ opererer modellen på den differensierte serien $\Delta y_t = y_t - y_{t-1}$.

Moving Average (MA) ledd av orden q inkluderer q tidligere prognosefeil som forklaringsvariabler:

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

der θ_i er MA-koeffisientene.

Autokorrelasjonsfunksjonen (ACF) og den partielle autokorrelasjonsfunksjonen (PACF) er viktige diagnostiske verktøy for å identifisere passende p - og q -verdier. Et signifikant ACF-lag ved forsinkelse k indikerer at observasjoner med avstand k er korrelerte (Hyndman & Athanasopoulos, 2021).

3.3 SARIMA – sesongbasert utvidelse

SARIMA(p, d, q)(P, D, Q, s) er en utvidelse av ARIMA som inkluderer sesongkomponenter med periode s (Box et al., 2015). For ukentlige mønstre i daglige data settes $s = 7$. De store bokstavene P, D, Q angir henholdsvis sesong-AR-orden, sesongdifferensiering og sesong-MA-orden. SARIMA-modellen fanger dermed opp både kortsiktig autokorrelasjon (via p, q) og periodiske mønstre med periode s dager (via P, Q).

Et signifikant ACF-lag ved forsinkelse s (eller multipler av s) indikerer at sesongkomponenten er til stede i dataene og at en SARIMA-modell vil beskrive serien bedre enn en ren ARIMA-modell. Hyndman og Athanasopoulos (2021) anbefaler å inkludere sesongkomponenter dersom ACF-koeffisienten ved forsinkelse s er statistisk signifikant.

3.4 Informasjonskriterium og modellvalg

Akaike's informasjonskriterium (AIC) er et mål for modellens tilpasning til dataene, justert for antall frie parametre (Hyndman & Athanasopoulos, 2021):

$$\text{AIC} = -2 \ln(\hat{L}) + 2k$$

der L er den maksimale likelihood-verdien og k er antallet estimerte parametre. En lavere AIC-verdi indikerer en bedre balanse mellom modellens tilpasning til treningsdataene og dens kompleksitet. AIC penaliserer dermed overparametriserte modeller og bidrar til å unngå overtilpasning.

3.5 Sikkerhetslager og servicegrad

Sikkerhetslager er en buffer av varer som holdes utover den forventede etterspørselen, for å beskytte mot etterspørselsusikkerhet og leveringsvariasjon (Silver et al., 2017). For en gitt servicegrad og normalfordelte prognosefeil kan sikkerhetslageret beregnes som:

$$SS = z_\alpha \cdot \sigma_L$$

der z_α er den korresponderende z-verdien fra normalfordelingen (for 95 % servicegrad er $z = 1,645$), og σ_L er standardavviket til prognosefeilen over planleggingshorisonten L .

I denne rapporten utnyttes at SARIMA-modellene leverer eksplisitte prediksjonsintervaller for prognosene. Et prediksjonsintervall angir spredningen til fremtidige enkeltobservasjoner og inkluderer både parameterusikkerhet og residualvarians – i motsetning til et konfidensintervall, som kun angir usikkerheten rundt en estimert parameter. Det øvre prediksjonsintervallet for 7-dagerssummen ved 95 % nivå gir dermed direkte det mengdenivået som dekker etterspørselen i 95 % av tilfellene. Sikkerhetslageret defineres som differansen mellom den øvre

prediksjongsgrensen og punktprognosen (jf. kapittel 6.4), som en praktisk implementasjon av den klassiske sikkerhetslagerformelen (Silver et al., 2017).

4 Casebeskrivelse

BiteBurst er en fiktiv hurtigmatkjede som driftes av én eier i dataspillet Big Ambitions (Hovgaard & Hovgaard, 2022). Big Ambitions er en forretningssimulator der spilleren bygger opp en virksomhet i New York fra grunnen av, og tar beslutninger om lokalisering, bemanning, sortiment, prissetting og leverandørrelasjoner. Spillet er utviklet av Hovgaard Games og har mottatt svært positive anmeldelser på Steam for sin dybde og realisme i forretningsmekanikken. For dette prosjektet er BiteBurst benyttet som et kontrollert simuleringsmiljø for å generere daglige salgsdata med en realistisk etterspørselslogikk, uten å måtte benytte konfidensielle data fra en reell bedrift.

Utsalgsstedene

BiteBurst opererer fire hurtigmatutsalgssteder lokalisert i ulike bydeler i New York slik de fremstår i spillet. Tabell 1 gir en oversikt over stedene med forkortelse, bydel og trafikkscore.

Tabell 1: Oversikt over BiteBursts utsalgssteder

Forkortelse	Bydel	Trafikkscore	Maks. kapasitet
GM	Garment District	46	30 kunder/time
HK	Hell's Kitchen	39	30 kunder/time
LM	Lower Manhattan	40	30 kunder/time
MH	Murray Hill	38	30 kunder/time

Trafikkscore i Big Ambitions er et mål på potensiell kundestrøm til en eiendom basert på bydelens fottrafikk. Alle fire utsalgsstedene har identisk lokal kapasitet på maksimalt 30 kunder i timen, like store lokaler og identiske åpningstider. Utsalgsstedene er konfigurert uten bruk av spillfunksjoner som reklame eller kampanjer for å minimere eksterne påvirkningsfaktorer på salget.

Til tross for relativt sammenlignbare trafikkscore-verdier selger Lower Manhattan (LM) vesentlig mer enn de tre øvrige stedene, noe Tabell 2 illustrerer. Tallene i tabellen er hentet fra SARIMA-prognosene presentert i kapittel 8 og er inkludert her for å gi kontekst til de utsalgsstedsrelaterte forskjellene.

Tabell 2: Ukentlig prognose per utsalgssted (alle produkter summert)

Utsalgssted	Prognose per uke (enheter)	Relativt til GM
GM	10 469	100 %
HK	11 402	109 %
LM	13 158	126 %
MH	10 832	103 %

Forklaringen ligger ikke i trafikkscoren alene, men i at Big Ambitions også opererer med en bydelsspesifikk *etterspørsel* som varierer mellom områder i spillet. Lower Manhattan er et høyaktivitetsområde i spillet med høyere innebygd etterspørsel etter hurtigmatprodukter enn de øvrige bydelene, noe som driver det høyere salgsvolumet. Dette skillet mellom trafikkscore og bydeletterspørsel er en viktig egenskap ved spillets simulering. For modelleringen innebærer det at individuelle SARIMA-modeller per utsalgssted er nødvendige, fremfor én felles modell for alle.

Produktsortiment

Alle fire utsalgsstedene selger de samme åtte produktkategoriene: Pizza, Salat, Pommes frites, Hamburger, Pølse, Brus, Iskrem og Kebab. Produktene ble valgt av eier innenfor de valgmulighetene spillets forretningsstype tillater, og representerer et bredt standardsortiment for en hurtigmatrestaurant. Innkjøpsprisen er identisk for alle utsalgssteder, mens utsalgsprisen kan variere. Siden kostnadsanalyse er avgrenset ut av rapporten (jf. kapittel 1.2), er dette ikke av direkte relevans for analysene.

Forsyningskjeden

Forsyningskjeden i BiteBurst er bygget opp i to ledd. Utsalgsstedene mottar daglig levering fra et sentrallager som eier har opprettet, med levering hver natt klokken 02:00. Sentrallageret på sin side bestiller varer fra en grossist og mottar levering hver mandag klokken 08:00, noe som etablerer en ukentlig bestillingssyklus oppstrøms i kjeden.

Denne strukturen er direkte relevant for problemstillingen. Under normal drift fylles utsalgsstedenes lagre daglig fra sentrallageret. Den analytiske utfordringen rapporten adresserer er imidlertid dimensjoneringen av det interne lageret på hvert utsalgssted: hvor mye varer må hvert sted holde for å klare syv dagers drift dersom den daglige leveransen fra sentrallageret skulle falle bort? Svaret på dette spørsmålet er bestemmende for utsalgsstedenes beredskapslagernivå og er det sentrale resultatet i rapporten.

Simuleringens styrker og begrensninger

Bruk av Big Ambitions som datagrunnlag er et bevisst valg av et kontrollert testmiljø for den metodiske pipelinen. Simuleringen gir en konsistent og stabil

etterspørselslogikk uten konfidensielle hensyn, ingen eksogene sjokk som kampanjer eller sesongavvik utenfor spillets logikk, og mulighet til å akkumulere data over en lengre periode enn det som normalt ville vært mulig å innhente fra en reell bedrift i et avgrenset prosjekt. Disse egenskapene gjør det mulig å evaluere metodikken under realistiske, men reproduserbare betingelser – en funksjon spillsimulatoren deler med laboratorieeksperimenter innen naturvitenskap. Datainnsamlingen foregår manuelt ved daglig avlesning av salgstall i spillgrensesnittet, noe som setter et praktisk tak på observasjonsperioden og kan introdusere enkeltfeil i registreringen.

Det er viktig å understreke at Big Ambitions er et kommersielt underholdningsspill, og at den underliggende etterspørselslogikken ikke er transparent for spilleren. Hvorvidt spillets algoritmer gjenspeiler reelle etterspørselsmønstre i hurtigmatbransjen, er ikke mulig å verifisere direkte. Den metodiske analyserekken er likevel fullt overførbar til reelle data, og simuleringskonteksten begrenser primært den eksterne validiteten av de substansielle funnene, ikke verdien av selve metodikken.

5 Metode og data

5.1 Metode

Begrunnelse for valg av SARIMA Valget av SARIMA som prognosemodell ble motivert av to analyser gjennomført på de rensede salgsseriene: stasjonærhetstest og autokorrelasjonsanalyse.

Stasjonærhetstesting (ADF): Augmented Dickey-Fuller-testen ble anvendt på alle 32 salgsserier. For et flertall av produktene på alle utsalgssteder – spesielt de med moderat til sterk trend – ble nullhypotesen om enhetsrot ikke avvist på 5 %-nivå ($p > 0,05$). Dette indikerer ikke-stasjonærhet og nødvendiggjør differensiering, det vil si $d = 1$. For produkter med relativt stabile nivåer (eksempelvis Iskrem og Brus) ble serien i noen tilfeller vurdert som nær-stasjonær, men sesongdifferensiering ble likevel vurdert separat.

Autokorrelasjonsanalyse (ACF): For alle 32 serier ble ACF-koeffisienten ved lag 1 beregnet og funnet svært høy (0,77–0,99). Det bemerkes at deler av denne høye lag-1-korrelasjonen er et konstruert artefakt av den rullerende 7-dagers sumstrukturen, der seks av syv dager overlapper mellom påfølgende observasjoner. Denne overlappingen alene vil mekanisk generere høy autokorrelasjon ved korte lag, uavhengig av den underliggende etterspørselsstrukturen. Av særlig interesse er lag 7: signifikante ACF-koeffisienter ($|r| > 0,20$) ved forsinkelse 7 ble observert eksplisitt for Pommes frites, Pølse, Kebab og Salat på tvers av utsalgsstedene. For øvrige produkter (Pizza, Hamburger, Brus, Iskrem) var lag-7-verdiene lavere, men sesongkomponenten ble likevel valgt av `auto_arima` for samtlige – noe som reflekterer at søket var begrenset til $s = 7$ som fast sesongperiode. Resultatene er dermed betinget på dette valget, og sesongkomponentens statistiske styrke

varierer mellom produktgrupper. Samlet sett støtter ACF-analysen valget av SARIMA med ukessyklus, og det er det syvende prognosestegets prediksjonsintervall som benyttes i sikkerhetslagerberegningen.

Samlet sett gir ADF-testen grunnlag for differensiering og ACF-analysen grunnlag for sesongkomponenten. SARIMA(p, d, q)(P, D, Q, 7) ble valgt som modellklasse for alle 32 kombinasjoner av produkt og utsalgssted.

Figur 1 viser ACF og PACF for HK Pommes frites etter førstedifferensiering. Signifikante korrelasjoner ved lag 7 (og multipler) i begge plottene bekrefter den ukentlige sesongstrukturen visuelt og underbygger valget av $s = 7$ i SARIMA-modellen.




Figure 1: ACF og PACF – HK Pommes frites

Figur 1: ACF og PACF for Pommes frites ved Hell's Kitchen (førstedifferensiert serie). Røde stiplede linjer markerer lag 7 og multipler. Blå skravert felt angir 95 % konfidensgrenser. Kilde: Egne beregninger.

Begrunnelse for SARIMA fremfor alternativer: Som gjennomgått i kapittel 2.4 finnes det tre relevante alternativer. Holt-Winters ble fravalgt fordi prosjektets sikkerhetslagerberegning er direkte avhengig av statistisk velfunderte prediksjonsintervaller; SARIMA leverer slike gjennom eksplisitt residualvariansestimering, mens Holt-Winters' konfidensintervaller hviler på enklere antakelser som gir dårligere kalibrering ved sesongmønstre av den typen som er observert her (Hyndman & Athanasopoulos, 2021). SARIMAX ble fravalgt fordi datagrunnlaget ikke inneholder registrerte eksterne forklaringsvariabler – spillet eksponerer ikke kampanje- eller værdata systematisk. Maskinlæringsmetoder ble fravalgt på grunn av utilstrekkelig datamengde: med 87–94 treningsobser-

vasjoner er stabilt regularisert trening av gradientboosting- eller LSTM-modeller ikke realistisk.

Metodiske implikasjoner av rullerende sumstruktur for prediksjonsintervaller

Den rullerende 7-dagers sumstrukturen innebærer at seks av syv dager overlapper mellom påfølgende observasjoner: y_t og y_{t+1} deler seks felles dagsobservasjoner. Dette skaper en mekanisk korrelasjon mellom residualene i SARIMA-modellen som er strukturelt uavhengig av den underliggende etterspørselen. SARIMA-modellen forutsetter at restleddet ϵ_t er hvit støy – det vil si uavhengige og identisk fordelte feil. Overlappende summer bryter formelt sett denne forutsetningen, siden residualene fra to påfølgende observasjoner alltid vil bære et innebygget korrelasjonsbidrag fra de seks delte dagene.

I praksis kan dette ha to konsekvenser: (1) residualvariansen som modellen estimerer kan bli undervurdert, fordi en del av korrelasjonsstrukturen feilaktig absorberes som modellforklart signal fremfor genuint stokastisk støy, og (2) AIC-sammenligningene mellom modeller kan bli noe misvisende dersom alle modeller berøres likt. Den første konsekvensen er særlig relevant for sikkerhetslagerberegningen: dersom residualvariansen er undervurdert, vil prediksjonsintervallene være smalere enn fullt ut berettiget, og sikkerhetslageret vil systematisk undervurdere reell usikkerhet. Prediksjonsintervallene fra denne analysen bør derfor tolkes som konservative nedre estimater på reell etterspørselsvariasjon.

Et alternativ ville vært å rekonstruere ikke-overlappende daglige salgstall fra differansene mellom påfølgende 7-dagerssummer og tilpasse SARIMA på disse. Dette ville eliminert den mekaniske korrelasjonsstrukturen, men ville introdusert støy fra spillets diskrete registreringslogikk og dramatisk redusert det effektive antallet treningsobservasjoner. I denne rapporten er analysen gjennomført direkte på de registrerte rullerende summene, i tråd med den datastrukturen spillet eksponerer.

Automatisk modellvalg med `auto_arima` Modellparametrene (p , d , q , P , D , Q) ble valgt automatisk ved hjelp av funksjonen `auto_arima` fra Python-biblioteket `pmdarima` (Hyndman & Athanasopoulos, 2021). Funksjonen implementerer en trinnvis (*stepwise*) søkeprosedyr der parametre inkrementelt justeres og ulike modellkombinasjoner sammenlignes basert på AIC-verdien. Modellen med lavest AIC velges som den endelige modellen. Parameterrommet som ble utforsket var:

- p , q : 0–3 (ikke-sesongmessige AR- og MA-ledd)
- d : automatisk bestemt (basert på KPSS- og ADF-tester internt i `auto_arima`)
- P , Q : 0–2 (sesongmessige AR- og MA-ledd)
- D : automatisk bestemt
- Sesongperiode $s = 7$

Trenings- og valideringsopplegg For å evaluere modellenes prediktive nøyaktighet ble det benyttet en rullerende prognosevalidering (*rolling-origin validation*) med to vinduer, slik at MAPE-estimatene ikke hviler på et enkelt valideringssett alene:

- **Valideringsvindu 2 (V2, primært):** Modellen tilpasses på treningsdataene (dag 1–94) og prognostiserer dag 95–101.
- **Valideringsvindu 1 (V1, tillegg):** Modellen tilpasses på dag 1–87 og prognostiserer dag 88–94.

To vinduer er valgt som et pragmatisk kompromiss gitt datamengden: et tredje vindu ville gitt et treningssett fra dag 1–80 (80 observasjoner), som er i nedre grense for stabil parameterestimering av SARIMA(p,d,q)(P,D,Q,7)-modeller med opp til ni frie parametre. Anbefalt lagernivå og sikkerhetslager er beregnet fra V2-modellen, da denne utnytter flest tilgjengelige observasjoner. MAPE rapporteres for begge vinduer samt som gjennomsnitt, noe som gir et mer robust bilde av modellytelsen enn et enkelt valideringspunkt. Gjennomsnittlig absolutt prosentfeil (MAPE) mellom prognose og faktisk valideringssett ble beregnet som mål på modellnøyaktighet:

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100\%$$

Sikkerhetslagerberegning Sikkerhetslageret ble beregnet direkte fra SARIMA-modellens 95 %-prediksjonsintervall for 7-dagerssummen. Den øvre prediksjonsgrensen representerer det nivået som – gitt modellens estimerte usikkerhet – dekker etterspørselen med 95 % sannsynlighet. Sikkerhetslageret defineres som:

$$SS = \text{PI}_{\text{øvre}, 7d} - \hat{F}_{7d}$$

der $\text{PI}_{\text{øvre}, 7d}$ er den øvre 95 %-prediksjonsgrensen for det syvende prognosesteget, og $\hat{F}_{7d}$ er punktprognosen for samme steg. Fordi dataene er rullerende 7-dagerssummer fra spillet, representerer det syvende prognosesteget direkte den predikerte totale etterspørselen for de neste syv dagene. Den anbefalte bestillingsmengden for én uke er dermed:

$$\text{Anbefalt} = \hat{F}_{7d} + SS = \text{PI}_{\text{øvre}, 7d}$$

Denne fremgangsmåten er i tråd med den klassiske sikkerhetslagerformelen (Silver et al., 2017) og utnytter den modellspesifikke usikkerheten direkte fremfor å benytte en generisk standardavviksbasert tilnærming.

5.2 Data

Datainnsamling Salgsdata ble samlet inn manuelt ved daglig avlesning av salgstallene i Big Ambitions for hvert av de fire utsalgsstedene. Data ble registrert i separate CSV-filer (semikolonseparert) for hvert utsalgssted, samt én fil for sentrallageret. Registreringen dekker en sammenhengende periode på 101 observasjoner (dag 1 til 101) for alle fem datakilder, noe som tilsvarer om lag 14 fullstendige uker. Hvert utsalgssted har én rad per dag med følgende kolonner: dagnummer, rullerende 7-dagers salgsvolum per produkt (åtte kolonner) og ukedag. Spillgrensesnittet eksponerer salget som rullerende 7-dagerssummer («sold last 7 days»), ikke enkeltdagssalg. Denne datastrukturen innebærer at påfølgende observasjoner overlapper med seks felles dager, noe som skaper konstruert autokorrelasjon i serien uavhengig av den underliggende etterspørselsstrukturen. Dette er redegjort for i avsnitt 5.1.

Datarensing Ved innledende dataanalyse ble det identifisert et antall verdier som avvek markant fra det øvrige datagrunnlaget. En 3-sigma-regel ble benyttet systematisk for å flagge potensielle feil, der verdier som avviker mer enn tre standardavvik fra seriens gjennomsnitt ble vurdert nærmere. Flaggede verdier ble videre klassifisert som enten isolerte utliggere midt i tidsserien, eller kanteffekter ved begynnelsen og slutten av observasjonsperioden, da disse tolkes ulikt med hensyn til datakvalitet.

Følgende registreringsfeil ble identifisert og korrigert av datainnhenter:

Tabell 3: Identifiserte og korrigerte registreringsfeil

Fil	Produkt	Opprinnelig verdi	Vurdering
LM	Pommes frites	23 330	Trolig tastefeil
LM	Kebab	22 360	Trolig tastefeil
HK	Pølse	18 235	Trolig tastefeil
HK	Kebab	4 357 (dag 86)	Isolert utligger ($z=8,0$)
GM	Kebab	184	Manglende siffer
MH	Kebab	198	Manglende siffer
GM	Pommes frites	356	Manglende siffer

Sentrallagerdata hadde noe høyere leveransevolum de første tre dagene (dag 1–3) for Pizza, Brus og Iskrem. Dette ble bekreftet som korrekte verdier som skyldes innledende opplasting av lagerkapasitet ved simuleringens oppstart, og ble ikke korrigert. Tilsvarende ble to forhøyede enkeltdagsverdier for Salat og Kebab på dag 7 bekreftet korrekte etter manuell gjennomgang av originalregistreringen.

Etter datarensing er alle fem CSV-filer komplette med 101 sammenhengende observasjoner og uten gjenværende isolerte utliggere.

Deskriptiv statistikk Etter datarensing ble det beregnet beskrivende statistikk for alle produkter per utsalgssted. Verdiene er basert på de registrerte rullerende 7-dagerssummene («sold last 7 days»), ikke enkelt dagssalg. Tabellene 4–7 presenterer nøkkeltall per utsalgssted.

Tabell 4: Deskriptiv statistikk for rullerende 7-dagers salgsvolum – GM (etter datarensing)

Produkt	Gjennomsnitt	Std.avvik	Minimum	Maksimum
Pizza	1 185	27	1 104	1 242
Salat	750	147	606	1 200
Pommes frites	1 752	398	1 275	2 421
Hamburger	2 187	63	2 043	2 376
Pølse	1 444	349	1 019	2 001
Brus	1 084	37	998	1 161
Iskrem	576	20	516	620
Kebab	1 941	64	1 677	2 049

Tabell 5: Deskriptiv statistikk for rullerende 7-dagers salgsvolum – HK (etter datarensing)

Produkt	Gjennomsnitt	Std.avvik	Minimum	Maksimum
Pizza	1 120	29	1 035	1 191
Salat	814	98	610	1 103
Pommes frites	1 989	261	1 575	2 306
Hamburger	2 042	82	1 760	2 205
Pølse	1 804	77	1 624	1 946
Brus	1 007	39	918	1 081
Iskrem	545	22	483	586
Kebab	1 641	198	1 321	1 856

Tabell 6: Deskriptiv statistikk for rullerende 7-dagers salgsvolum – LM (etter datarensing)

Produkt	Gjennomsnitt	Std.avvik	Minimum	Maksimum
Pizza	1 386	45	1 287	1 497
Salat	1 388	48	1 234	1 481
Pommes frites	1 877	376	1 244	2 625
Hamburger	2 555	96	2 181	2 736
Pølse	2 369	320	1 839	2 832
Brus	1 001	31	924	1 083
Iskrem	627	86	517	766

Produkt	Gjennomsnitt	Std.avvik	Minimum	Maksimum
Kebab	2 323	140	2 061	2 697

Tabell 7: Deskriptiv statistikk for rullerende 7-dagers salgsvolum – MH (etter datarensing)

Produkt	Gjennomsnitt	Std.avvik	Minimum	Maksimum
Pizza	1 115	51	1 020	1 353
Salat	852	51	765	1 086
Pommes frites	1 775	415	1 074	2 320
Hamburger	2 072	102	1 734	2 463
Pølse	2 072	219	1 683	2 367
Brus	1 014	46	856	1 118
Iskrem	546	17	515	587
Kebab	2 048	219	1 710	2 389

Det fremgår at det er stor variasjon i standardavvik mellom produktene, og at mønsteret er konsistent på tvers av utsalgsstedene. Pommes frites og Pølse har gjennomgående vesentlig høyere variasjon enn eksempelvis Iskrem og Brus. Kebab viser moderat til lav variasjon etter at registreringsfeilene ble korrigert. LM skiller seg ut med høyere absolutte salgstall for de fleste produkter, men har ikke nødvendigvis høyere relativ variasjon.

Høy standardavvik innebærer større usikkerhet i etterspørselsprognosene og dermed et høyere nødvendig sikkerhetslager. Dette vil være en gjennomgående observasjon i resultatkapittelet: produkter med høy variasjon krever en forholdsmessig større buffer utover selve prognosen for å oppnå ønsket servicegrad.

6 Modellering

6.1 SARIMA-formulering

Den tilpassede SARIMA(p, d, q)(P, D, Q, 7)-modellen for en gitt tidsserie kan skrives som:

$$\Phi_P(B^7) \phi_p(B) (1 - B)^d (1 - B^7)^D y_t = \Theta_Q(B^7) \theta_q(B) \varepsilon_t$$

der B er tilbakeskiftoperatoren ($By_t = y_{t-1}$), $\phi_p(B)$ og $\Phi_P(B^7)$ er henholdsvis de ikke-sesongmessige og sesongmessige AR-polynomene, og $\theta_q(B)$

og $\Theta_Q(B^7)$ de tilsvarende MA-polynomene. Faktoren $(1-B)^d$ sikrer ikke-sesongmessig stasjonæritet og $(1-B^7)^D$ sesongmessig stasjonæritet. t er hvit støy.

I praksis ble modellparametrene estimert ved maksimum likelihood via `auto_arima`, og det ble benyttet $D = 0$ for alle modeller i dette datasettet – sesongmønsteret er fanget opp gjennom sesong-AR- og MA-ledd (P, Q) fremfor sesongdifferensiering.

6.2 Automatisk parametertilpasning

For å unngå manuell identifisering av SARIMA-ordre for alle 32 produkt-utsalgsstedskombinasjoner ble `auto_arima` fra `pmdarima` benyttet med AIC som informasjonskriterium og trinnvis søk aktivert. Funksjonen gjennomfører internt stasjonæritetstest (KPSS-test) for å bestemme d , og ADF-test for å bestemme D . Søkerommet var avgrenset til $p, q \in \{0, 1, 2, 3\}$ og $P, Q \in \{0, 1, 2\}$ for å holde beregningstiden nede og redusere risikoen for overtilpasning.

6.3 Tilpassede modeller – oversikt

Tabell 8 gir en komplett oversikt over de 32 tilpassede SARIMA-modellene med modellordre og AIC-verdi. Alle modeller fikk en sesongkomponent ($P > 0$ eller $Q > 0$ med $s = 7$), noe som bekrefter at ukessyklusen er statistisk vesentlig på tvers av alle produkt-utsalgsstedskombinasjoner.

Tabell 8: Oversikt over tilpassede SARIMA-modeller

Utsalgssted	Produkt	ARIMA-orden	Sesong-orden	AIC
GM	Pizza	(0,1,1)	(0,0,1,7)	739,19
GM	Salat	(1,1,1)	(0,0,1,7)	722,00
GM	Pommes frites	(1,1,1)	(2,0,0,7)	901,01
GM	Hamburger	(1,0,0)	(2,0,0,7)	893,48
GM	Pølse	(1,1,1)	(0,0,2,7)	853,56
GM	Brus	(2,0,0)	(2,0,0,7)	818,28
GM	Iskrem	(1,0,0)	(2,0,1,7)	661,06
GM	Kebab	(2,0,1)	(2,0,0,7)	910,44
HK	Pizza	(2,0,1)	(2,0,0,7)	767,09
HK	Salat	(1,1,3)	(0,0,1,7)	702,27
HK	Pommes frites	(1,1,0)	(2,0,1,7)	904,90
HK	Hamburger	(1,1,2)	(0,0,1,7)	860,67
HK	Pølse	(0,1,0)	(0,0,1,7)	855,94
HK	Brus	(1,0,0)	(2,0,1,7)	784,70
HK	Iskrem	(3,0,0)	(2,0,0,7)	690,09
HK	Kebab	(1,1,0)	(0,0,1,7)	869,14
LM	Pizza	(0,1,0)	(0,0,1,7)	813,04
LM	Salat	(0,1,2)	(0,0,1,7)	798,67
LM	Pommes frites	(1,1,1)	(2,0,0,7)	967,05

Utsalgssted	Produkt	ARIMA-orden	Sesong-orden	AIC
LM	Hamburger	(3,1,1)	(1,0,0,7)	907,53
LM	Pølse	(2,1,0)	(0,0,1,7)	914,65
LM	Brus	(0,1,0)	(0,0,1,7)	759,23
LM	Iskrem	(1,1,1)	(0,0,1,7)	699,98
LM	Kebab	(1,1,0)	(0,0,1,7)	903,50
MH	Pizza	(0,1,0)	(2,0,0,7)	755,14
MH	Salat	(1,0,0)	(2,0,0,7)	743,50
MH	Pommes frites	(1,1,0)	(2,0,0,7)	927,84
MH	Hamburger	(2,0,1)	(2,0,0,7)	912,85
MH	Pølse	(0,1,3)	(0,0,1,7)	891,18
MH	Brus	(0,1,0)	(0,0,1,7)	818,97
MH	Iskrem	(1,0,0)	(2,0,1,7)	657,24
MH	Kebab	(1,1,0)	(0,0,1,7)	906,58

Modellordene varierer mellom produkt og utsalgssted, noe som reflekterer at de individuelle salgsseriene har ulik korrelasjonstruktur. Enklere modeller som SARIMA(0,1,0)(0,0,1,7) – som tilsvarer en sesongmessig random walk med MA-ledd – er valgt for produkter med lite systematisk autokorrelasjon utover sesongmønsteret, mens mer komplekse modeller med høyere p - og q -verdier er valgt der dataene viser sterkere avhengighetsstruktur.

6.4 Beregning av sikkerhetslager og anbefalt ordre

For hver tilpasset modell ble SARIMA-prognosen fremskrevet syv steg, og et 95 %-prediksjonsintervall ble konstruert for hvert steg basert på modellens estimerte residualvarians. Fordi de registrerte salgsdata er rullerende 7-dagerssummer («sold last 7 days» i spillet), representerer det syvende prognosesteget direkte den predikerte totale etterspørselen for de neste syv dagene. Det er dette stegets prediksjonsintervall som benyttes.

Anbefalt bestillingsmengde for én uke settes lik den øvre 95 %-prediksjonsgrensen for det syvende prognosesteget, og sikkerhetslageret er differansen mellom denne øvre grensen og punktprognosen for samme steg (jf. kapittel 5.1). Kildekoden som implementerer denne beregningen er tilgjengelig i vedlegg C.

7 Analyse

7.1 Modellnøyaktighet

Tabellene 9a–9c sammenfatter MAPE-verdiene fra den rullerende prognosevalideringen med to vinduer for alle 32 modeller. V1 = dag 88–94 (modell tilpasset dag 1–87), V2 = dag 95–101 (modell tilpasset dag 1–94). Gjennomsnittlig

MAPE over begge vinduene gir et mer robust mål på modellytelsen enn ett enkelt valideringspunkt.

Tabell 9a: SARIMA MAPE (%) – Valideringsvindu V1 (dag 88–94)

Produkt	GM	HK	LM	MH
Pizza	3,3	1,8	3,4	0,8
Salat	3,1	1,8	1,3	2,8
Pommes frites	3,2	0,6	11,8	11,3
Hamburger	1,5	0,6	1,5	1,1
Pølse	1,8	3,3	11,0	6,6
Brus	2,7	2,1	2,7	4,0
Iskrem	1,0	2,7	2,5	1,4
Kebab	3,1	2,8	6,4	5,9

Tabell 9b: SARIMA MAPE (%) – Valideringsvindu V2 (dag 95–101)

Produkt	GM	HK	LM	MH
Pizza	3,1	0,8	2,3	9,2
Salat	4,2	15,7	1,5	16,4
Pommes frites	16,0	1,5	2,0	21,6
Hamburger	5,4	0,8	0,8	8,9
Pølse	19,9	2,0	7,3	7,7
Brus	1,3	4,9	1,6	0,8
Iskrem	2,6	5,0	4,3	1,8
Kebab	1,1	3,1	5,1	2,2

Tabell 9c: SARIMA MAPE (%) – Gjennomsnitt V1 og V2

Produkt	GM	HK	LM	MH
Pizza	3,2	1,3	2,8	5,0
Salat	3,6	8,8	1,4	9,6
Pommes frites	9,6	1,1	6,9	16,4
Hamburger	3,4	0,7	1,1	5,0
Pølse	10,9	2,7	9,2	7,2
Brus	2,0	3,5	2,1	2,4
Iskrem	1,8	3,9	3,4	1,6
Kebab	2,1	2,9	5,8	4,1

For å dokumentere verdien SARIMA tilfører utover en triviell metode, er modellenes MAPE sammenlignet mot en naiv prognose der den siste observerte rullerende 7-dagerssummen brukes uendret som prognose for alle syv fremtidige

steg. Tabell 9d viser de tilsvarende MAPE-verdiene for den naive referanseprognosen (V2-vinduet), og Tabell 9e i seksjon 7.5 rapporterer Ljung-Box residualdiagnostikk.

Tabell 9d: Naiv referanseprognose MAPE (%) – siste observasjon fremskrevet per produkt og utsalgssted (V2)

Produkt	GM	HK	LM	MH
Pizza	5,4	1,0	3,7	9,5
Salat	10,4	14,9	1,8	17,3
Pommes frites	16,8	1,6	5,5	24,5
Hamburger	5,7	0,9	1,3	8,9
Pølse	16,5	3,9	2,4	6,6
Brus	2,4	2,8	4,1	2,9
Iskrem	2,0	3,0	4,0	2,3
Kebab	1,9	1,2	1,9	2,2

Sammenligningen viser at SARIMA gjennomgående gir lavere MAPE enn den naive referanseprognosen: for 24 av 32 kombinasjoner i V2-vinduet er SARIMA-MAPE lavere. De tydeligste forbedringene finnes for produkter med strukturert sesongmønster, som GM Salat (SARIMA 4,2 % mot naiv 10,4 %) og LM Pommes frites (SARIMA 2,0 % mot naiv 5,5 %). I åtte tilfeller er den naive referanseprognosen marginalt bedre eller likeverdig, og disse sammenfaller stort sett med produkter der etterspørselen var relativt flat i valideringsperioden, slik at siste observasjon tilfeldigvis var et godt estimat.

En sammenligning av V1- og V2-MAPE-verdiene (Tabell 9a og 9b) gir viktig tilleggsinformasjon: for de fleste produkter er ytelsen relativt stabil mellom de to periodene, noe som styrker tilliten til modellene. Det mest slående unntaket er Murray Hill, der V2-MAPE konsekvent er vesentlig høyere enn V1-MAPE for Pizza (V1: 0,8 %, V2: 9,2 %), Salat (2,8 % mot 16,4 %), Pommes frites (11,3 % mot 21,6 %) og Hamburger (1,1 % mot 8,9 %). Dette bekrefter at salget ved MH akselererte spesielt mot slutten av observasjonsperioden og at V2-MAPE-tallene dermed reflekterer et trendskifte snarere enn generell modellsvakheter. Det gjennomsnittlige MAPE over begge vinduene (Tabell 9c) gir et mer balansert bilde enn V2 alene.

For et klart flertall av modellene (24 av 32) er V2-MAPE under 8 %, noe som generelt regnes som god prognoseytelse (Hyndman & Athanasopoulos, 2021). Åtte modeller har MAPE over 8 %, og av disse har fem MAPE over 15 %. Disse tilhører hovedsakelig to produktkategorier – Pommes frites og Salat – og ett utsalgssted – Murray Hill (MH).

For produkter der V2-MAPE overstiger 15 % er prognosenøyaktigheten i et område som i operasjonell sammenheng normalt betegnes som utilstrekkelig for direkte bruk (Hyndman & Athanasopoulos, 2021). Her er det imidlertid nyttig å skille mellom to mønstre basert på to-vinduvalideringen:

- **Begge vinduer høye** – indikerer strukturell modellsvakhet: MH Pommes frites (V1: 11,3 %, V2: 21,6 %, snitt: 16,4 %) og GM Pølse (V1: 1,8 %, V2: 19,9 %, snitt: 10,9 %). For disse anbefales et erfaringspåslag på 15–20 % på anbefalt bestillingsmengde, inntil modellen er reestimert på et lengre og mer stabilt datagrunnlag.
- **Kun V2 høy, V1 lav** – indikerer et trendsifte i siste periode snarere enn generell modellsvakhet: MH Salat (V1: 2,8 %, V2: 16,4 %, snitt: 9,6 %) og HK Salat (V1: 1,8 %, V2: 15,7 %, snitt: 8,8 %). For disse er gjennomsnitts-MAPE under 10 %, og et fullt erfaringspåslag er ikke nødvendigvis berettiget. En viss årvåkenhet overfor trendsifter i siste periode er likevel anbefalt.

Lagernivåanbefalingene for produkter i den første kategorien bør ikke benyttes ukritisk uten manuell vurdering.

De produktene som gjennomgående gir lav MAPE (Brus, Iskrem, Kebab, Hamburger) kjennetegnes av relativt lav standardavvik i salgsvolum (jf. Tabellene 4–7) og stabil etterspørselsstruktur. Disse er dermed de enkleste å prognostisere. Produkter med høy standardavvik – Pommes frites og i noen grad Pølse – gir mer varierende MAPE, avhengig av utsalgssted.

7.2 Bekreftet ukessyklus

Alle 32 modeller fikk automatisk valgt en sesongkomponent ($P > 0$ eller $Q > 0$ med $s = 7$). Dette er en sterk empirisk bekreftelse på at ukessyklusen er statistisk relevant og systematisk på tvers av alle produkter og utsalgssteder. Mønsteret med lavere salg midt i uken og høyere salg i helg/fredag, som ble identifisert i den innledende dataanalysen, er dermed godt ivaretatt av SARIMA-modellene.

7.3 Pommes frites og Pølse: høy variasjon og heterogen modellytelse

Figur 2 viser den rullerende 7-dagers salgsutviklingen for Pommes frites ved alle fire utsalgssteder gjennom hele observasjonsperioden. Det fremgår tydelig at HK har det høyeste salgsvolumet for dette produktet, og at alle fire seriene har en oppadgående tendens mot slutten av perioden – med MH som den mest markante.

Figur 2: Pommes frites – rullerende 7-dagerssum per utsalgssted. Lys grå sone: V1-valideringsvindu (dag 88–94). Mørkere grå sone: V2-valideringsvindu (dag 95–101). Kilde: Egne beregninger.

Pommes frites og Pølse utmerker seg med de høyeste standardavvikene på tvers av utsalgsstedene (jf. Tabellene 4–7). Denne grunnleggende variasjonen i salgsvolum gjenspeiles direkte i modellresultatene. For GM gir Pommes frites V2-MAPE = 16,0 % og Pølse V2-MAPE = 19,9 %, noe som skyldes at det faktiske salgsnivået i valideringsperioden var i en oppadgående trend som modellen ikke fanget fullt ut. Det er verdt å merke seg at V1-MAPE for de samme produktene




Figure 2: Pommes frites – rullerende 7-dagers salg per utsalgssted

er henholdsvis 3,2 % og 1,8 %, noe som bekrefter at den høye V2-feilen skyldes en trend i siste periode fremfor iboende modellsvakhhet. Tilsvarende mønster ses for MH Pommes frites (V2-MAPE = 21,6 %, V1 = 11,3 %) og MH Salat (V2-MAPE = 16,4 %, V1 = 2,8 %).

Interessant nok presterer de samme produktene svært godt ved andre utsalgssteder: HK Pommes frites gir MAPE = 1,5 % og HK Pølse MAPE = 2,0 %. Figur 3 illustrerer dette med et eksempel på et godt modelltilpasset tilfelle.




Figure 3: SARIMA-prognose HK – Pommes frites

Figur 3: SARIMA-prognose for Pommes frites ved Hell's Kitchen (V1-MAPE = 0,6 %, V2-MAPE = 1,5 %). Blå linje: treningsdata. Grå stiplet: faktisk validering. Oransje: prognose med 95 % prediksjonsintervall. Grå sone: valideringsperiode (dag 95–101). Kilde: Egne beregninger.

Dette indikerer at den høye MAPE-en ikke er iboende for produktet alene, men er et resultat av samspillet mellom produkt og utsalgssted i den konkrete observasjonsperioden – spesielt der salgsserien hadde en mer utpreget trend mot

slutten av observasjonsperioden.

7.4 Trendeffekter i Murray Hill

Murray Hill (MH) skiller seg ut med gjennomgående høyere MAPE enn de øvrige utsalgsstedene i V2-vinduet. En systematisk gjennomgang av de faktiske valideringsverdiene mot prognosen viser at faktisk salg i de siste syv dagene (dag 95–101) konsekvent overstiger SARIMA-prognosen for Pizza, Pommes frites, Hamburger og Salat. Eksempel: for MH Pommes frites er prognosen for siste 7-dagersvindu 1 511 enheter, mens faktisk siste rullerende 7-dagerssum er 2 236 – et avvik på nær 48 % for denne enkeltobservasjonen (V2-MAPE på 21,6 % er gjennomsnittet over alle syv valideringsdager). Til sammenligning er V1-MAPE for MH Pommes frites 11,3 %, noe som viser at problemet eskalerte mot periodens slutt.

Dette mønsteret er forenlig med en oppadgående salgsandel i MH som ikke var fullt etablert over de foregående 94 treningsdagene. SARIMA-modellene er designet for stasjonære eller svakt trendende serier, og har begrenset evne til å ekstrapolere en akselererende veksttrend over det historiske nivået. Dette er en klar begrensning som vil bli adressert i diskusjonskapittelet.

Figur 4 viser SARIMA-prognosen for MH Pommes frites, der det tydelig fremgår at prognosen (oransje) systematisk ligger under de faktiske valideringsverdiene (grå stiple).




Figure 4: SARIMA-prognose MH – Pommes frites

Figur 4: SARIMA-prognose for Pommes frites ved Murray Hill (V1-MAPE = 11,3 %, V2-MAPE = 21,6 %). Prognosen (oransje) undervurderer systematisk de faktiske valideringsverdiene (grå stiple), noe som reflekterer den oppadgående salgstendensen i slutten av observasjonsperioden. Grå sone: valideringsperiode (dag 95–101). Kilde: Egne beregninger.

Til tross for denne svakheten er sikkerhetslageranbefalingene for MH robuste i den forstand at de høye prediksjonsintervallene reflekterer den store usikkerheten, og anbefalt bestillingsmengde inkluderer en relativt større buffer for de

produktene der MAPE er høy.

7.5 Residualdiagnostikk

For å verifisere at SARIMA-modellene har fanget opp all systematisk struktur i dataene, ble Ljung-Box-testen for gjenværende autokorrelasjon gjennomført på residualene fra hver av de 32 modellene. Testen tester nullhypotesen om at residualene er uavhengige (hvit støy) mot alternativet om at det er gjenværende autokorrelasjon. En p-verdi over 0,05 innebærer at nullhypotesen ikke forkastes, noe som er ønsket.

Tabell 9e: Ljung-Box p-verdi (lag 7) per produkt og utsalgssted

Produkt	GM	HK	LM	MH
Pizza	1,0000	0,3715	1,0000	1,0000
Salat	0,9999	1,0000	0,9998	0,1259
Pommes frites	0,9999	1,0000	1,0000	0,9991
Hamburger	0,6163	1,0000	0,9990	0,6289
Pølse	1,0000	1,0000	1,0000	1,0000
Brus	0,9765	0,2848	1,0000	0,9780
Iskrem	0,1136	0,0148 *	1,0000	0,2331
Kebab	0,8786	0,9999	1,0000	1,0000

* $p < 0,05$: mulig gjenværende autokorrelasjon i residualene.

For 31 av 32 modeller er Ljung-Box p-verdien ved lag 7 godt over 0,05, noe som betyr at nullhypotesen om ingen gjenværende autokorrelasjon ikke forkastes. Residualene fremstår dermed som hvit støy for nesten alle modellene, og modellspesifikasjonene er tilfredsstillende. Unntaket er HK Iskrem ($p = 0,0148$), der testen indikerer at noe struktur er igjen i residualene. For dette produktet bør prediksjonsintervallet tolkes med noe forsiktighet.

Figur 5 illustrerer residualdiagnostikken visuelt for et representativt eksempel – GM Brus, som har Ljung-Box $p = 0,98$ og er en av de mest stabile seriene i datasettet. Venstre panel viser at de standardiserte residualene er tilnærmet tilfeldige rundt null, uten systematiske mønstre. Høyre panel viser ACF av residualene, der ingen lag er statistisk signifikante – et tydelig kjennetegn på hvit støy.

Figur 5: Residualdiagnostikk for Brus ved Garment District. Venstre: standardiserte residualer over tid med ± 2 std.avvik-grenser. Høyre: ACF av residualer med 95 % konfidensgrenser – ingen signifikante lag bekrefter hvit støy. Kilde: Egne beregninger.




Figure 5: Residualdiagnostikk – GM Brus

8 Resultat

Kapitlet presenterer det sentrale resultatet av analysen: anbefalt ukentlig bestillingsmengde per produkt per utsalgssted ved 95 % servicegrad. Bestillingsmengden er definert som summen av 7-dagers etterspørselsprognose og sikkerhetslager, og tilsvarende lagernivået hvert utsalgssted må holde for å kunne operere i syv dager uten levering fra sentrallager.

8.1 Garment District (GM)

Tabell 10: Anbefalte lagernivåer for GM – uke (enheter, 95 % servicegrad)

Produkt	Prognose 7d	Sikkerhetslager	Anbefalt ordre
Pizza	1 219	55	1 273
Salat	1 108	111	1 219
Pommes frites	1 381	312	1 694
Hamburger	2 172	98	2 270
Pølse	995	264	1 259
Brus	1 088	76	1 164
Iskrem	568	29	596
Kebab	1 938	136	2 073
Totalt	10 469	1 081	11 548

GM er utsalgsstedet med høyest trafikkscore (46), men ikke høyest samlet salgsvolum. Hamburger og Kebab dominerer sortimentet volumsmessig. Sikkerhetslageret er relativt lite for stabile produkter som Iskrem (29 enheter, 5 % av prognosen) og forholdsvis stort for Pommes frites (312 enheter, 23 % av prognosen) og Pølse (264 enheter, 27 %) som følge av høy salgsvariasjon. For GM Pølse, som har MAPE = 19,9 % i valideringssettet, bør anbefalt ordre betraktes med forsiktighet; et erfaringspåslag på 15–20 % gir en justert anbefaling på omtrent 1 450–1 510 enheter (mot beregnede 1 259 enheter).

8.2 Hell's Kitchen (HK)

Tabell 11: Anbefalte lagernivåer for HK – uke (enheter, 95 % servicegrad)

Produkt	Prognose 7d	Sikkerhetslager	Anbefalt ordre
Pizza	1 113	67	1 180
Salat	843	108	951
Pommes frites	2 250	371	2 621
Hamburger	2 034	166	2 200
Pølse	1 811	123	1 935
Brus	980	60	1 039
Iskrem	536	38	574
Kebab	1 835	334	2 169
Totalt	11 402	1 267	12 669

HK skiller seg ut ved at Pommes frites er det klart mest solgte produktet med 2 250 enheter i 7-dagersprognosen – merkbart høyere enn de øvrige produktene og vesentlig høyere enn tilsvarende verdi for GM (1 381). Sikkerhetslageret for Pommes frites (371) og Kebab (334) er de to høyeste enkeltpostene. Til tross for dette gir SARIMA-modellen for HK Pommes frites en svært lav MAPE på 1,5 %, noe som indikerer at det høye sikkerhetslagerbehovet skyldes iboende etterspørselsusikkerhet over 7-dagershorisonten, ikke modellusikkerhet.

8.3 Lower Manhattan (LM)

Tabell 12: Anbefalte lagernivåer for LM – uke (enheter, 95 % servicegrad)

Produkt	Prognose 7d	Sikkerhetslager	Anbefalt ordre
Pizza	1 388	99	1 487
Salat	1 435	90	1 525
Pommes frites	1 646	457	2 103
Hamburger	2 651	134	2 785
Pølse	2 010	362	2 373
Brus	1 016	74	1 090
Iskrem	516	94	610
Kebab	2 496	255	2 751
Totalt	13 158	1 565	14 724

Lower Manhattan er klart det utsalgsstedet med høyest totalt salgsvolum, med en 7-dagersanbefaling på 14 724 enheter – om lag 27 % mer enn GM. Som beskrevet i casebeskrivelsen skyldes dette bydelens høyere innebygde

etterspørsel i spillsimulasjonen, ikke trafikkscoren alene. Pommes frites har det høyeste sikkerhetslageret absolutt (457 enheter, 28 % av prognosen), mens Hamburger er det volumsmessig største enkeltproduktet med 2 651 enheter i prognosen.

8.4 Murray Hill (MH)

Tabell 13: Anbefalte lagernivåer for MH – uke (enheter, 95 % servicegrad)

Produkt	Prognose 7d	Sikkerhetslager	Anbefalt ordre
Pizza	1 115	73	1 188
Salat	821	54	875
Pommes frites	1 511	531	2 042
Hamburger	2 055	145	2 199
Pølse	1 895	261	2 157
Brus	1 008	103	1 111
Iskrem	550	29	579
Kebab	1 877	346	2 222
Totalt	10 832	1 542	12 373

MH har det høyeste sikkerhetslageret relativt til prognosen av alle utsalgsstedene (14,2 % av total prognosesum), noe som gjenspeiler den høyere etterspørselsikkerheten for dette stedet i observasjonsperioden. Pommes frites alene har et sikkerhetslager på 531 enheter – det høyeste av alle 32 modeller. Som vist i analysekapittelet hadde MH en oppadgående salgstendens i slutten av observasjonsperioden, og de faktiske siste rullerende 7-dagerssummene overskrider prognosen for flere produkter. Anbefalingene i Tabell 13 bør tolkes med dette forbeholdet. For produkter med $MAPE > 15\%$ – spesielt Pommes frites ($MAPE = 21,6\%$) – anbefales et erfaringspåslag på 15–20 % på anbefalt bestillingsmengde. For MH Pommes frites tilsvaret dette en justert anbefalt ordre på omtrent 2 350–2 450 enheter (mot de beregnet 2 042 enhetene i Tabell 13), og bør revurderes etter at en lengre og mer stabil observasjonsperiode er tilgjengelig.

8.5 Samlet oppsummering

Alle 32 SARIMA-modeller leverte konkrete lagernivåanbefalinger. For majoriteten av produkt-utsalgsstedskombinasjonene (24 av 32) ble $MAPE$ under 8 % oppnådd, noe som gir god tillit til at prognosene er representative for forventet etterspørsel. Sikkerhetslageret utgjør 10–14 % av total ukentlig prognose per utsalgssted, med størst buffer for produkter med høy salgsvariasjon (Pommes frites, Pølse, Kebab ved utvalgte steder).

Figur 6 gir en visuell oppsummering av lagernivåanbefalingene for alle 32 kombinasjoner. Den blå delen av hver søyle representerer punktprognosen og den oran-

sjø bufferen utgjør sikkerhetslageret. Produkter merket med * har V2-MAPE > 15 % og bør justeres manuelt.




Figure 6: Anbefalt ukentlig bestilling per produkt per utsalgssted

Figur 6: Anbefalt ukentlig bestillingsmengde per produkt per utsalgssted ved 95 % servicegrad. Blå: etterspørselsprognose. Oransje: sikkerhetslager. * = V2-MAPE > 15 %, anbefalt ordre bør justeres manuelt. Kilde: Egne beregninger.*

Produkter som Iskrem og Brus kjennetegnes ved svært stabile salgsvolumer og lav MAPE, og krever minimalt sikkerhetslager. Disse produktene er enkle å styre fra et lagerperspektiv. Pommes frites representerer det motsatte: høy salgsvariasjon, store prediksjonsintervaller og – avhengig av utsalgssted – moderat til høy modellusikkerhet. For dette produktet er en konservativ tilnærming til lagernivå særlig viktig for å unngå stockout.

9 Diskusjon

9.1 Modellnøyaktighet og praktisk implikasjon

Resultatene viser at SARIMA-modellene gir god prognoseytelse for majoriteten av produkt-utsalgsstedskombinasjonene: 24 av 32 modeller oppnår MAPE under 8 %, og de beste modellene leverer MAPE under 2 %. Dette er i tråd med hva man kan forvente av SARIMA på daglige salgsdata med tydelige ukemønstre (Hyndman & Athanasopoulos, 2021). Sett fra et lagerstyringsperspektiv er dette

et godt utgangspunkt: for produkter med lav MAPE er prediksjonsintervallet – og dermed sikkerhetslageret – direkte drevet av den iboende etterspørselsvariansen, ikke av modellusikkerhet. Lageranbefaling og faktisk behov vil i disse tilfellene typisk stemme godt overens.

For de åtte modellene med MAPE over 8 % er bildet mer nyansert. Her er det viktig å skille mellom to årsaker til høy prognosefeil: (1) iboende høy etterspørselsvariation som modellen ikke kan eliminere, og (2) systematiske avvik der modellen konsekvent under- eller overpredikerer som følge av at den historiske strukturen ikke lenger holder. For Pommes frites og Pølse ved GM, og for flere produkter ved MH, er det siste tilfellet som gjør seg gjeldende – noe som omtales nærmere i avsnitt 9.2 og 9.3.

I motsatt ende av spekteret er det verdt å bemerke at Iskrem og Brus konsekvent viser lav MAPE og lav etterspørselsvariation på tvers av alle fire utsalgsteder. For disse produktene er beregnet sikkerhetslager minimalt, og differansen i MAPE mellom SARIMA og naiv referansemodell er liten (jf. Tabell 9d). Dette reiser et spørsmål om ressursbruk: dersom etterspørselen er tilstrekkelig stabil til at en naiv fremskrivning gir akseptabel nøyaktighet, kan en enklere modell være lettere å forvalte over tid. Begrunnelsen for å benytte SARIMA likevel er at modellvalget gjøres enhetlig for alle 32 kombinasjoner, og at de statistisk velfunderte prediksjonsintervallene gir en direkte og konsistent kobling til sikkerhetslagerberegningen – uavhengig av om nøyaktighetsgevinsten isolert sett er stor eller liten for det enkelte produktet.

9.2 SARIMA-modellens begrensning ved trendende etterspørsel

Den viktigste begrensningen som avdekkes i analysen, er SARIMA-modellenes vanskelighet med å ekstrapolere en akselererende veksttrend utover det historiske nivået. Murray Hill (MH) viser et systematisk mønster der faktiske salgstall i valideringsperioden (dag 95–101) overstiger prognoseverdiene for flere produkter – mest markant for Pommes frites (faktisk salg ~48 % over prognose) og Hamburger. SARIMA er designet for stasjonære eller svakt trendende serier og vil, ved tilpasning på 94 dager, i hovedsak ekstrapolere den gjennomsnittlige vekstraten over treningsperioden. Dersom vekstkurven har akselerert mot slutten av observasjonsperioden, vil modellen systematisk underpredikere (Box et al., 2015).

En praktisk konsekvens er at lagernivåanbefalingene for MH – særlig for Pommes frites – bør behandles med et konservativt påslag inntil en lengre og mer stabil observasjonsperiode er tilgjengelig. Alternativt kan en kortere, rullerende treningsvindu (for eksempel de siste 30–60 dagene) gi modeller som er mer responsive til nylige trendskifter, på bekostning av at sesongkomponenten estimeres med færre observasjoner.

Det er viktig å understreke at dette ikke nødvendigvis er en svakhet ved SARIMA som metode, men heller et tegn på at 101 observasjoner kan være utilstrekkelig som treningsgrunnlag dersom etterspørselen er i en tidlig vek-

stfase. Med et lengre datasett der vekstkurven stabiliserer seg, vil SARIMA ha bedre forutsetninger for å fange opp den underliggende strukturen. Det er likevel en grunnleggende egenskap ved SARIMA – og lineære tidsrekkemodeller generelt – at de er reaktive fremfor prediktive overfor brå trendsifter: modellen ekstrapolerer hva den har sett, og kan uten eksogene variabler ikke forutse en akselerasjon den ikke har observert. Årsaken er strukturell: SARIMA estimerer én gjennomsnittlig differanseverdi (Δy) over treningsperioden og ekstrapolerer denne som en konstant. En eksponentiell vekstbane – der selve vekstraten øker fra periode til periode – krever at differanseverdien selv vokser, noe en modell med $d = 1$ og ingen eksogene variabler ikke kan representere. SARIMAX-utvidelsen adresserer nettopp dette ved å la en eksogen variabel bære informasjon om den underliggende vekstdriveren (Arunraj et al., 2016). Dette er illustrert i Figur 4 for MH Pommes frites og er et argument for å supplere SARIMA med domenebaserte justeringer i perioder med kjent strukturendring.

9.3 Heterogen modellytelse for Pommes frites og Pølse

Pommes frites og Pølse utmerker seg med det høyeste standardavviket blant produktene på tvers av alle utsalgssteder, og dette gjenspeiles i varierende modellytelse. Den interessante observasjonen er at de samme produktene kan gi svært lav MAPE ved ett utsalgssted (HK Pommes frites: 1,5 %, HK Pølse: 2,0 %) og svært høy ved et annet (GM Pølse: 19,9 %, MH Pommes frites: 21,6 %). Dette peker på at den underliggende årsaken er utsalgsstedsspesifikk, ikke produktspesifikk.

En plausibel forklaring er at salgsseriene for disse produktene ved de «gode» utsalgsstedene hadde en relativt stabil sesongstruktur gjennom hele observasjonsperioden, mens de ved de «svake» utsalgsstedene hadde en mer ustabil trend. SARIMA-modellen er sensitiv for slike strukturbrudd fordi den tilpasses som en helhet over hele treningsperioden, uten å vekte nylige observasjoner høyere. Denne svakheten er godt kjent i litteraturen og er en av motivasjonene for metoder som eksponentiell utjevning med dempet trend, som gir høyere vekt til nylige observasjoner (Hyndman & Athanasopoulos, 2021).

9.4 Sikkerhetslagerberegningens validitet

Beregningen av sikkerhetslager direkte fra SARIMA-prediksjonsintervallet forutsetter at prognosefeilene er tilnærmet normalfordelte. Denne forutsetningen er innebygd i maksimum likelihood-estimeringen i SARIMA-modellen og er en standardantagelse som holder godt for mange stabile tidsrekker, men som kan brytes for serier med sporadiske sprang eller skjev fordeling (Box et al., 2015). For produktene og utsalgsstedene der MAPE er lav, er det rimelig å anta at normalfordelingsantagelsen holder tilfredsstillende. For MH i vekstfase er den mer diskutabel.

Figur 7 viser residualfordelingen for to kontrasterende kombinasjoner – Brus

ved GM (stabil, lav MAPE) og Pommes frites ved MH (høy MAPE, veksttrend). For GM Brus er residualene godt sentrert rundt null og følger normalfordelingen tett; Shapiro-Wilk-testen gir $p = 0,256$, og nullhypotesen om normalfordeling kan ikke forkastes. For MH Pommes frites er bildet annerledes: fordelingen viser en markert asymmetri som gjenspeiler den systematiske underprediksjonen i vekstperioden, og Shapiro-Wilk gir $p < 0,001$. Dette bekrefter at prediksjonsintervallet – og dermed sikkerhetslageret – for denne kombinasjonen bør tolkes med varsomhet, i tråd med anbefalingen i avsnitt 9.2 om et konservativt påslag for MH.




Figure 7: Residualfordeling

Figur 7: Residualfordeling for Brus ved Garment District (venstre) og Pommes frites ved Murray Hill (høyre). Rød kurve viser teoretisk normalfordeling $N(0, 1)$. Shapiro-Wilk-teststatistikk er angitt i hvert panel. Kilde: Egne beregninger.

En praktisk begrensning er at prediksjonsintervallene fra SARIMA kan bli svært vide for modeller med høy residualvarians, noe som fører til store sikkerhetslagre. For Pommes frites ved MH er sikkerhetslageret 531 enheter (35 % av prognosen), noe som reflekterer den reelle usikkerheten, men som også kan bidra til overlapping dersom trenden stabiliserer seg. Det er derfor hensiktsmessig å revurdere lagernivåanbefalingene periodisk, fremfor å behandle dem som statiske referanseestørrelser.

Ljung-Box-testen for gjenværende autokorrelasjon i residualene er gjennomført for alle 32 modeller og rapportert i Tabell 9e (seksjon 7.5). For 31 av 32 modeller er p-verdien godt over 0,05, noe som støtter normalfordelingsantagelsen og gir tillit til prediksjonsintervallene. Det ene unntaket er HK Iskrem ($p = 0,0148$), der prediksjonsintervallet potensielt er noe undervurdert. Sikkerhetslageret for dette produktet (38 enheter ved HK) er lavt i absolutt forstand, og konsekvensen av undervurderingen er dermed begrenset i praktisk kontekst.

En ytterligere begrensning som bør fremheves, er knyttet til den rullerende 7-dagers sumstrukturen som er diskutert i kapittel 5.1. Overlappende summer medfører at SARIMA-modellens residualvarians potensielt er undervurdert, fordi den mekaniske korrelasjonen mellom påfølgende observasjoner delvis absorberes som modellforklart struktur. Konsekvensen er at prediksjonsinterval-

lene – og dermed sikkerhetslageret – kan være noe smalere enn de ville vært på ikke-overlappende daglige data. Sikkerhetslagernivåene i Tabellene 10–13 bør forstås i lys av dette: de representerer nedre estimater for reell usikkerhet, og et forsiktig tillegg utover de beregnede intervallene vil i de fleste tilfeller være en fornuftig operasjonell beslutning.

9.5 Simuleringens overføringsverdi til reelle data

En åpenbar innvending mot prosjektets datagrunnlag er at Big Ambitions er et dataspill, og at etterspørselslogikken i spillet ikke nødvendigvis gjenspeiler dynamikken i reelle hurtigmatrestauranter. Det er rimelig å forvente at reelle data vil ha mer eksogene påvirkningsfaktorer – vær, kampanjer, konkurrenter, lokale hendelser – som ikke er representert i spillets simulering. I tillegg er selve registreringsprosessen manuell, noe som introduserer risiko for enkeltfeil (jf. datarensingskapittelet).

Disse forbeholdene til tross, er metodikken som er utviklet i rapporten fullt overførbart til reelle forretningsdata. Den sentrale metodiske analyserekken – stasjonærhetstest, ACF-analyse, automatisk SARIMA-tilpasning med AIC, prediksjonsintervallbasert sikkerhetslager – fungerer uavhengig av om dataene er simulerte eller reelle. Det som ville endre seg ved overgang til reelle data, er (1) behovet for mer robust datarensing og håndtering av manglende verdier, (2) muligheten for å inkludere eksternt påvirkende variabler som kampanjer via SARIMAX-utvidelsen, og (3) periodisk reestimering av modellparametrene etter hvert som nye data akkumuleres. Simuleringskonteksten har dermed fungert som et kontrollert testmiljø for metodikken, uten de konfidensialitetshensyn som ville fulgt med reelle bedriftsdata.

9.6 Alternative metoder

De tre hovedalternativene til SARIMA – Holt-Winters, SARIMAX og maskinlæringsmetoder – er presentert og sammenlignet i kapittel 2.4. Resultatene i denne rapporten kaster ytterligere lys over når disse alternativene ville vært mer hensiktsmessige.

Holt-Winters' egenskap om å vekte nylige observasjoner høyere fremstår som særlig relevant i lys av Murray Hill-problematikken: en modell som reagerer raskere på akselererende vekst ville potensielt gitt lavere MAPE for MH i V2-vinduet. For steder med stabil etterspørsel (HK, LM, GM for de fleste produkter) er imidlertid denne fordelene liten, mens SARIMA-prediksjonsintervallene gir en direkte kobling til sikkerhetslagerberegningen som Holt-Winters ikke tilbyr like direkte. SARIMAX fremstår som det mest naturlige neste steget dersom kampanje- eller hendelsesdata gjøres tilgjengelige – Arunraj et al. (2016) viser at utvidelsen er særlig virksam for volatile produktkategorier, og Pommefrites og Pølse ville vært åpenbare kandidater. ML-metoders datakrav er ikke innfridd med 101 observasjoner, men ville vært aktuelle ved overgang til reelle forretningsdata med flere år historikk.

For å dokumentere at SARIMA tilfører verdi utover en triviell metode, er SARIMA-resultatene sammenlignet mot en naiv referanseprognose der siste observerte rullerende 7-dagerssum fremskrives uendret for alle syv prognosetrinn. Sammenligningen er presentert i Tabell 9d (seksjon 7.1). SARIMA gir lavere MAPE enn den naive referanseprognosen for 24 av 32 kombinasjoner, og forbedringen er størst for produkter med tydelig sesongstruktur og trend – eksempelvis GM Salat (4,2 % mot 10,4 %) og LM Pommes frites (2,0 % mot 5,5 %). For de åtte kombinasjonene der naive er likeverdig eller marginalt bedre, er salgsserien i valideringsperioden relativt flat, slik at siste observasjon tilfeldigvis er et godt estimat. Dette bekrefter at SARIMA utnytter den historiske strukturen, men at metodefordelen er størst der etterspørselen har tydelig autokorrelasjon og sesongmønster.

10 Konklusjon

Rapporten undersøkte hvordan SARIMA-basert etterspørselsprognose kan benyttes til å fastsette optimalt lagernivå per produkt per utsalgssted for hurtigmatbedriften BiteBurst, slik at hvert utsalgssted kan operere i syv dager uten levering fra sentrallager.

Delspørsmål 1 – Modellvalg: For alle 32 kombinasjoner av produkt og utsalgssted ble det identifisert en SARIMA-modell med sesongperiode $s = 7$ som den best tilpassede modellen etter AIC-kriteriet. Sesongkomponenten ble valgt automatisk for samtlige modeller, noe som bekrefter at en statistisk målbar ukentlig salgssyklus er til stede i dataene på tvers av alle produkter og utsalgssteder. Modellordene varierer betydelig mellom kombinasjonene – fra enkle random walk-modeller med sesong-MA-ledd til mer komplekse modeller med høyere AR- og MA-orden – noe som understreker behovet for individuelle modeller fremfor én felles modell. Valideringen med to rullerende prognosevinduer viser at 24 av 32 modeller oppnår MAPE under 8 % i det primære valideringsvinduet (V2: dag 95–101), noe som klassifiseres som god prognoseytelse. Det gjennomsnittlige MAPE over begge vinduene bekrefter at ytelsen er stabil for de fleste produkt-utsalgsstedskombinasjonene, med tydelig unntaksstruktur knyttet til Murray Hills veksttrendperiode.

Delspørsmål 2 – Lagernivåer: Basert på 7-dagers SARIMA-prognoser og 95 %-prediksjonsintervaller er det beregnet konkrete lagernivåanbefalinger for alle 32 produkt-utsalgsstedskombinasjonene. Anbefalt ukentlig bestillingsmengde per utsalgssted er 11 548 enheter for GM, 12 669 for HK, 14 724 for LM og 12 373 for MH. Sikkerhetslageret utgjør 10–14 % av total prognosesum per utsalgssted, med størst buffer for produkter med høy salgsvariasjon (Pommes frites, Pølse og Kebab). Produktene Iskrem og Brus er de enkleste å styre: lav variasjon, lav MAPE og minimalt sikkerhetslager.

Et viktig forbehold er knyttet til Murray Hill, der en oppadgående salgsten-dens mot slutten av observasjonsperioden indikerer at SARIMA-modellene kan

underpredikere fremtidig etterspørsel for dette utsalgsstedet. Det anbefales å re-vurdere lagernivåene for MH etter at en lengre og mer stabil observasjonsperiode er tilgjengelig.

Videre arbeid: Metodikken er direkte overførbar til reelle forretningsdata, og et naturlig neste skritt er å validere tilnærmingen mot faktiske salgstall fra en reell hurtigmatkjede. Inkludering av eksogene variabler via SARIMAX-modellen, samt periodisk reestimering av modellparametrene, vil øke robustheten i en operasjonell setting. For utsalgssteder i rask vekst kan en kortere, rullerende treningsvindu vurderes for å gi mer responsive prognoser.

11 Bibliografi

Arunraj, N. S., & Ahrens, D. (2015). A hybrid seasonal autoregressive integrated moving average and quantile regression for daily food sales forecasting. *International Journal of Production Economics*, 170, 321–335. <https://doi.org/10.1016/j.ijpe.2015.09.039>

Arunraj, N. S., Ahrens, D., & Fernandes, M. (2016). Application of SARI-MAX model to forecast daily sales in food retail industry. *International Journal of Operations Research and Information Systems*, 7(2), 1–21. <https://doi.org/10.4018/IJORIS.2016040101>

Babai, M. Z., Ali, M. M., Boylan, J. E., & Syntetos, A. A. (2013). Forecasting and inventory performance in a two-stage supply chain with ARIMA(0,1,1) demand: Theory and empirical analysis. *International Journal of Production Economics*, 143(2), 463–471. <https://doi.org/10.1016/j.ijpe.2011.09.004>

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5. utg.). Wiley.

Chopra, S., & Meindl, P. (2019). *Supply chain management: Strategy, planning, and operation* (7. utg.). Pearson.

Fattah, J., Ezzine, L., Aman, Z., El Moussami, H., & Lachhab, A. (2018). Forecasting of demand using ARIMA model. *International Journal of Engineering Business Management*, 10. <https://doi.org/10.1177/1847979018808673>

Gilbert, K. (2005). An ARIMA supply chain model. *Management Science*, 51(2), 305–310. <https://doi.org/10.1287/mnsc.1040.0308>

Hovgaard, M., & Hovgaard, S. (2022). *Big Ambitions* [PC-spill]. Hovgaard Games.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3. utg.). OTexts. <https://otexts.com/fpp3/>

Silver, E. A., Pyke, D. F., & Thomas, D. J. (2017). *Inventory and production management in supply chains* (4. utg.). CRC Press.

12 Vedlegg

Vedlegg A – Deskriptiv statistikk alle utsalgssteder

Fullstendig deskriptiv statistikk (gjennomsnitt, standardavvik, minimum, maksimum) for alle produkter og alle utsalgssteder er tilgjengelig i 005 `report/core.json` under nøkkelen `sales_statistics`.

Vedlegg B – SARIMA-resultater

Fullstendige modellresultater (modellorden, AIC, MAPE, prognose, sikkerhetslager, anbefalt lagernivå) for alle 32 modeller er tilgjengelig i 005 `report/sarima_results.json`.

Vedlegg C – Python-kode

Kildekoden for SARIMA-modelleringen er tilgjengelig i 005 `report/sarima_model.py`.